



Audiência Compartilhada em Transmissões ao Vivo no YouTube: Mapeamento via Coeficiente de Jaccard e Visualizações Multivariadas

Janderson Pereira,¹ Walter Soares Antonio Junior,² Junior Fernandes Marques,³ Afonso Paiva Neto⁴

Universidade de São Paulo (USP) – Instituto de Ciências Matemáticas e de Computação (ICMC) –
Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria (MECAI)

1 Introdução

As mensagens de chat em transmissões ao vivo (*live streams*) no YouTube expõem a identidade pública do comentarista via `channel_id`, permitindo o rastreamento longitudinal de indivíduos entre canais distintos [1]. Diferentemente das métricas de consumo passivo (visualizações, inscritos, *watch time*), esse sinal constitui evidência de engajamento ativo e rastreável sem coleta de dados privados.

No jornalismo digital brasileiro, a fragmentação de audiência entre veículos concorrentes é pouco estudada quantitativamente [7]. Compreender quanto do público é compartilhado tem implicações para decisões editoriais, planejamento de mídia e inteligência competitiva.

Este trabalho apresenta uma metodologia computacional para medir a sobreposição de audiência ativa entre 12 canais brasileiros de jornalismo no YouTube durante 30 dias (20/05/2026 a 20/06/2026), integrando três eixos: (i) dados multivariados por PCA e dendrograma de Ward, (ii) análise textual por TF-IDF, t-SNE e cruzamento fala–chat, e (iii) grafos de similaridade via coeficiente de Jaccard.

Para ter acesso aos códigos, os dados agregados anonimizados e outras visualizações, clique aqui para acessar o site .

¹janderson.pereira@usp.br

²waltersoares@usp.br

³junior.marques@usp.br

⁴apneto@usp.br

2 Metodologia

2.1 Coleta e anonimização

Os dados foram obtidos via YouTube Data API v3 e *chat replay* público, cobrindo: metadados de vídeo (título, horário, duração), métricas de audiência simultânea (CCV), mensagens de chat (texto, *offset*, *super chat*) e transcrições automáticas. Visando conformidade com a LGPD [3], nenhum `channel_id` real é persistido: cada identificador é substituído por SHA-256 com *salt* fixo, preservando a capacidade de unir registros sem expor dados pessoais. O recorte final está descrito na Tabela 1.

Tabela 1: Estatísticas do conjunto de dados (período 20/05/2026–20/06/2026).

Grandeza	Valor
Canais monitorados	12
Transmissões ao vivo	2.133
Mensagens de chat	1.855.415
Autores únicos	98.881
Autores em ≥ 2 canais	12.374 (12,5%)

2.2 Eixo A — Dados multivariados

Cada canal é representado por oito métricas padronizadas (*z-scores*): número de transmissões, total de mensagens, autores únicos, mensagens por mil visualizações, pico médio de CCV, duração mediana, proporção de recorrentes e valor total de *super chat*. A Análise dos Componentes Principais (PCA) [8] reduz esse espaço para visualização bidimensional; o dendrograma hierárquico usa o critério de Ward [6], que minimiza a variância intra-cluster a cada fusão. A Figura 1 apresenta a projeção resultante.

2.3 Eixo B — Documentos e textos

TF-IDF [4] representa as mensagens de chat após remoção de *stopwords*. A projeção t-SNE [5] posiciona cada transmissão (25 amostras por canal) de forma que vocabulários semelhantes apareçam próximos. O cruzamento de frequências entre transcrições (fala do canal) e chat (Figura 2) quantifica termos amplificados ou suprimidos pelo público.

2.4 Eixo C — Grafos de sobreposição

Seja A_i o conjunto de autores únicos do canal i . O índice de Jaccard [2] entre canais i e j é

$$J(i, j) = \frac{|A_i \cap A_j|}{|A_i \cup A_j|} \in [0, 1]. \quad (1)$$

A matriz 12×12 resultante alimenta um grafo ponderado e o diagrama de cordas (Figura 3), que evidencia a magnitude e a distribuição da circulação de público entre canais.




Figura 1: Eixo A: PCA dos 12 canais (>55% da variância nos dois primeiros componentes). Figura 2: Eixo B: Cruzamento fala–chat. Pontos acima da diagonal indicam amplificação pelo público. Figura 3: Eixo C: Diagrama de cordas. Espessura proporcional ao número de autores compartilhados.

3 Resultados e Discussão

Eixo A. O plano PCA (Figura 1) revela três perfis: (a) canais de grande alcance e chat intenso (CNN Brasil, Revista Oeste, Jovem Pan News); (b) canais de nicho (Poder360, TV Cultura Jornalismo, Band Jornalismo); e (c) TV 247, isolado pelos altos valores de recorrência de audiência e *super chat*, padrão reforçado pelo dendrograma de Ward.

Eixo B. No cruzamento fala–chat (Figura 2), nomes de figuras políticas (“lula”, “bolsonaro”, “moraes”) são, fortemente, amplificados pelo público em relação à fala dos apresentadores. Termos de contextualização jornalística (“decreto”, “processo”) ficam abaixo da diagonal de equilíbrio — o chat polariza mais do que informa, padrão consistente com *live streaming* [1]. A projeção t-SNE confirma aglomerados temáticos coerentes com o viés editorial declarado de cada canal.

Eixo C. O maior coeficiente de Jaccard foi $J = 0,0553$ (CNN Brasil – Jovem Pan News). Mais de 90% dos pares apresentou $J < 0,03$, indicando públicos predominantemente distintos. O diagrama de cordas (Figura 3) torna visível que as cordas mais espessas ligam os três canais de maior alcance, enquanto canais de nicho (Poder360, TV Cultura) têm circulação mínima de público. Ainda assim, 12,5% dos comentaristas (12.374 indivíduos) circularam por dois ou mais canais — fluxo *cross-editorial* estrategicamente relevante para anunciantes e gestores de programação.

4 Conclusões

A integração do coeficiente de Jaccard com PCA, dendrograma de Ward, t-SNE e análise fala-chat permite caracterizar, de forma simultânea e com baixo custo, sobreposição de público, perfis de engajamento e proximidade temática entre canais concorrentes. Embora os públicos sejam majoritariamente segmentados ($J_{\max} = 0,0553$), a fração de 12,5% que circula entre canais é estrategicamente relevante. A metodologia é replicável para outros nichos e janelas temporais, com alinhamento à LGPD [3]. Como próximos passos, pretende-se ampliar a janela temporal, explorar análise de sentimento supervisionada em português e publicar o *dataset* agregado anonimizado.

Reforçamos a sugestão para que acesse o site para verificar a análise completa, com outras visualizações. clique aqui para acessar o site .

Referências

- [1] W. A. Hamilton, O. Garretson e A. Kerne. Streaming on Twitch: Fostering participatory communities of play within the live streamed video game ecosystem. In *Proc. CHI*, pp. 1315–1324. ACM, 2014. DOI: 10.1145/2556288.2557048.
- [2] P. Jaccard. The distribution of the flora in the alpine zone. *New Phytologist*, 11(2):37–50, 1912. DOI: 10.1111/j.1469-8137.1912.tb05611.x.
- [3] Brasil. Lei n.º 13.709, de 14 de agosto de 2018 — *Lei Geral de Proteção de Dados Pessoais (LGPD)*. Diário Oficial da União, Brasília, 2018.
- [4] G. Salton e C. Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988. DOI: 10.1016/0306-4573(88)90021-0.
- [5] L. van der Maaten e G. Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- [6] J. H. Ward Jr. Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301):236–244, 1963. DOI: 10.1080/01621459.1963.10500845.
- [7] J. G. Webster e T. B. Ksiazek. The dynamics of audience fragmentation: Public attention in an age of digital media. *Journal of Communication*, 62(1):39–56, 2012. DOI: 10.1111/j.1460-2466.2011.01616.x.
- [8] S. Wold, K. Esbensen e P. Geladi. Principal component analysis. *Chemometrics and Intelligent Laboratory Systems*, 2(1–3):37–52, 1987. DOI: 10.1016/0169-7439(87)80084-9.